Fatores associados à dificuldade percebida no aprendizado de programação

Survey transversal com estudantes de cursos de tecnologia: períodos iniciais e estagiários

Ana Luiza Santos Gomes, Bruna Barbosa Portilho Bernardes, Guilherme Augustto Costa Barros e Vinícius Dias
Pontifícia Universidade Católica de Minas Gerais (PUC Minas), Unidade Lourdes · Bacharelado em Engenharia de Software

Medição e Experimentação em Engenharia de Software (MEES) · 2º/2026
Registro: tag `protocolo-v1.0` em `github.com/guicostak/Trabalho-Final-Survey`

Ficha do estudo. Método: survey por questionário autoadministrado on-line, descritivo e correlacional, de corte transversal • **População:** estudantes de CC, ES, ADS e SI de instituições brasileiras, do 1º ao 4º período ou em estágio de TI • **Amostragem:** não probabilística, por conveniência com bola de neve, em vários canais e com metas por segmento • **Instrumento:** aceite do TCLE e 5 perguntas, mais 1 pergunta aberta opcional (cerca de 2 minutos) • **Amostra:** meta de 50 respostas válidas; margem de erro nominal de ±13,9 p.p. • **Hipóteses confirmatórias:** 5, testadas com $\alpha = 0{,}05$ e correção de Holm • **Coleta:** 18/11 a 04/12/2026. O protocolo segue o padrão *Questionnaire Surveys* e o suplemento *Registered Reports* dos ACM SIGSOFT Empirical Standards (RALPH et al., 2021) e foi registrado *antes* da primeira resposta. Qualquer desvio será datado, justificado e registrado em `DESVIOS.md`.

1 Objetivo e questões de pesquisa

Disciplinas introdutórias de programação têm reprovação elevada: a taxa média de aprovação fica próxima de dois terços (WATSON; LI, 2014). A literatura relaciona a dificuldade de aprender a programar a fatores de *entrada*, como a experiência prévia, a fatores *psicológicos*, como autoeficácia e ansiedade, e ao *conteúdo* estudado (ROBINS; ROUNTREE; ROUNTREE, 2003; LAHTINEN; ALA-MUTKA; JÄRVINEN, 2005; RAMALINGAM; WIEDENBECK, 1998; CONNOLLY; MURPHY; MOORE, 2009). Além disso, os assistentes de IA generativa mudaram a forma como os iniciantes estudam (BECKER et al., 2023). Este estudo caracteriza a dificuldade *percebida* (a percepção do estudante, não o seu desempenho) em quatro cursos de tecnologia e testa a sua associação com experiência prévia, curso, etapa do curso (períodos iniciais ou estágio) e uso de IA. Para favorecer a adesão, o instrumento foi reduzido a 5 perguntas, mantendo um construto medido por vários itens. O objetivo segue o template GQM (BASILI; CALDIERA; ROMBACH, 1994) (Tabela 1); as questões de pesquisa (QP) e as hipóteses estão na Tabela 2, e as métricas na Tabela 3.

Tabela 1: Objetivo de medição no template GQM.

Analisar	o processo de aprendizagem de programação na graduação
com o propósito de	caracterizar e identificar fatores associados
com respeito à	dificuldade percebida pelos estudantes
do ponto de vista	dos estudantes de graduação
no contexto de	cursos de Ciência da Computação (CC), Engenharia de Software (ES), Análise e Desenvolvimento de Sistemas (ADS) e Sistemas de Informação (SI) de instituições brasileiras, com estudantes do 1º ao 4º período ou em estágio de TI, no 2º semestre de 2026

Tabela 2: Questões de pesquisa e hipóteses (bilaterais; direção esperada entre parênteses).

QP	Pergunta	Hipóteses
QP1	Qual é o nível de dificuldade percebida no aprendizado de programação?	Descritiva, sem hipótese.
QP2	A dificuldade percebida difere entre estudantes com e sem experiência prévia em programação?	H2: M1 difere entre os grupos (maior sem experiência).
QP3	A dificuldade percebida varia conforme o curso e a etapa do curso?	H3a: M1 difere entre os cursos. H3b: M1 difere entre períodos iniciais e estagiários (menor entre estagiários). H3c: a experiência prévia está associada ao curso.
QP4	A dificuldade percebida está associada ao uso de IA generativa nos estudos?	H4: $\rho(\mathrm{M1}, \mathrm{M6}) \neq 0$ (sem direção esperada).

Tabela 3: Métricas: definição operacional, escala de medição e QP atendida.

ID	Métrica	Definição operacional	Escala	QP
M1	Dificuldade percebida	Média de DIF1–DIF4 (DIF4 invertido), de 1 a 5	Ordinal (escore)[a]	QP1–QP4
M2	Concordância por item	% de *concordo* ou *concordo totalmente* em cada item DIF	Razão (proporção)	QP1
M3	Experiência prévia	Programava antes de ingressar no curso (EXP)	Nominal	QP2, QP3
M4	Curso	CC, ES, ADS ou SI (CUR)	Nominal	QP3
M5	Etapa do curso	1º ao 4º período ou estagiário do 5º período em diante (ETA)	Nominal	QP3
M6	Uso de IA generativa	Frequência de uso de IA ao estudar (IAF), de 1 a 5	Ordinal	QP4
M7	Qualidade das respostas	% de respostas válidas e descartes por motivo (ACE, ATN1; regras E1–E6)	Razão (proporção)	QP1–QP4[b]
M8	Temas da questão aberta	Frequência de cada tema codificado em ABR	Nominal	QP1

[a]Itens Likert são ordinais; o escore médio entra no α de Cronbach, mas só é analisado com testes de postos. [b]Validade de todas as QPs.

2 População e amostragem

2.1 População-alvo. São estudantes de graduação em CC, ES, ADS e SI de instituições brasileiras, públicas ou privadas, com 18 anos ou mais, que estejam (a) do 1º ao 4º período ou (b) do 5º período em diante, fazendo estágio em TI. Estudantes formam a população de interesse, e não um substituto por conveniência: a dificuldade de aprender a programar se manifesta nos períodos iniciais, e os estagiários permitem contrastar quem já aplica programação em contexto profissional. Não existe lista nacional desses estudantes, e o tamanho exato da população é desconhecido, mas grande: o Censo da Educação Superior 2024 registra 10.226.873 matrículas de graduação no país (INEP, 2025). Os quatro cursos estudados são apenas uma parte desse total, mas, somando várias instituições, a população supera em muito 2.000 estudantes, e a correção para população finita é desprezível para $n = 50$. Ficam de fora os menores de 18 anos, que exigiriam autorização do responsável. Os colegas da disciplina MEES e os integrantes do grupo não recebem o convite e são orientados a não responder, porque conhecem as hipóteses do estudo.

2.2 Origem dos contatos e estratégia. Como não há quadro amostral, a amostragem é *não probabilística, por conveniência com bola de neve* (BALTES; RALPH, 2022). O convite parte de cinco fontes: (i) docentes de programação de outras instituições, contatados pelo grupo, que repassam o convite às turmas; (ii) centros e diretórios acadêmicos; (iii) grupos de estudantes de tecnologia (WhatsApp, Discord, Telegram), com permissão dos administradores; (iv) perfis dos integrantes no LinkedIn e no Instagram; (v) os próprios respondentes, convidados a repassar o link na mensagem final do formulário. Para que as comparações sejam viáveis, há **metas mínimas por segmento**: 8 respostas por curso e 10 estagiários. Em 25/11, a composição parcial é verificada, e a divulgação é direcionada aos segmentos abaixo da meta. A elegibilidade é verificada no próprio formulário (ACE, CUR e ETA).

2.3 Tamanho da amostra, margem de erro e poder. A meta é de **50 respostas válidas**, o mínimo exigido, considerada realista para um link aberto sem incentivos. A margem de erro de uma proporção com 95% de confiança é $e = 1{,}96\sqrt{p(1-p)/n}$, no pior caso $p = 0{,}5$, sem correção para população finita, porque a população é grande e de tamanho desconhecido. Como a amostra não é probabilística, essa margem é **nominal**: indica a precisão que uma amostra aleatória do mesmo tamanho teria e não garante representatividade (Seção 7). O poder estatístico é de 80% com $\alpha = 0{,}05$ bilateral (Tabela 4): com $n = 50$, só efeitos grandes ($|\rho| \geq 0{,}39$ ou $d \geq 0{,}81$) são detectáveis, e resultados não significativos não indicam ausência de efeito. Se a coleta superar a meta, a margem e o poder melhoram.

Tabela 4: Margem de erro nominal (95%) e menores efeitos detectáveis com poder de 80%, por tamanho de amostra.

Respostas válidas (n)	Margem de erro nominal	Menor $\lvert\rho\rvert$ detectável	Menor d detectável[c]
50 (meta e mínimo)	**±13,9 p.p.**	**0,39**	**0,81**
70	±11,7 p.p.	0,33	0,68
100	±9,8 p.p.	0,28	0,57

[c]Mann-Whitney com grupos de mesmo tamanho (eficiência relativa assintótica de 0,955 em relação ao teste t).

3 Questionário com rastreabilidade

O instrumento foi enxugado para favorecer a adesão: um aceite que funciona como porteira, **5 perguntas** e uma pergunta aberta opcional, com duração estimada de 2 minutos. Ele é aplicado no Microsoft Forms, aberto a qualquer pessoa com o link e configurado como *resposta anônima* (não registra nome nem e-mail). A plataforma registra o início e o fim de cada resposta, o que permite detectar respostas rápidas demais. As escalas Likert têm 5 pontos rotulados (1 = *discordo totalmente* … 5 = *concordo totalmente*), com ponto neutro. A redação segue as recomendações de Kitchenham e Pfleeger (2008). O construto **dificuldade percebida** (DIF) é medido por 4 itens, apresentados em uma única grade Likert: DIF1 e DIF2 cobrem conceitos e tradução da lógica em código, DIF3 cobre o início da resolução de problemas e DIF4 é invertido para reduzir a aquiescência. A **pergunta de atenção** (ATN1) é uma linha da mesma grade. Respostas que indicam inelegibilidade

encerram o formulário por ramificação. A redação completa está em `instrumento/questionario.md`, e a Tabela 5 liga cada item a uma escala, a uma métrica e a uma QP.

Tabela 5: Matriz de rastreabilidade do questionário (item → escala → métrica → QP). ^{R} = item de codificação invertida.

ID	Item	Escala	Métrica	QP
Aceite (porteira, antes das perguntas)				
ACE	Li o termo acima, tenho 18 anos ou mais e concordo em participar (*não concordo* encerra)	Nominal	M7	QP1–QP4
Pergunta 1 — Curso				
CUR	Qual é o seu curso? CC, ES, ADS, SI ou *outro* (*outro* encerra)	Nominal	M4	QP3
Pergunta 2 — Etapa do curso				
ETA	1º ao 4º período; 5º período ou posterior com estágio em TI; 5º período ou posterior sem estágio (encerra)	Nominal	M5	QP3
Pergunta 3 — Experiência prévia				
EXP	Antes de ingressar no curso, você já havia programado (curso livre, ensino técnico, sozinho etc.)?	Nominal	M3	QP2, QP3
Pergunta 4 — Grade Likert de dificuldade percebida (construto DIF) com verificação de atenção				
DIF1	Tenho dificuldade para compreender novos conceitos de programação	Ordinal (Likert 5)	M1, M2	QP1–QP4
DIF2	Tenho dificuldade para transformar a lógica de uma solução em código	Ordinal (Likert 5)	M1, M2	QP1–QP4
DIF3	Com frequência, não sei por onde começar a resolver um problema de programação	Ordinal (Likert 5)	M1, M2	QP1–QP4
DIF4^{R}	Consigo acompanhar o ritmo das disciplinas de programação sem grandes dificuldades	Ordinal (Likert 5)	M1, M2	QP1–QP4
ATN1	**Atenção:** "Para confirmar que você está lendo com atenção, marque *Discordo totalmente* nesta linha"	Nominal (acerto)	M7	QP1–QP4
Pergunta 5 — Uso de IA generativa				
IAF	Com que frequência você usa assistentes de IA generativa ao estudar programação? (nunca, raramente, às vezes, frequentemente, sempre)	Ordinal (5 pts)	M6	QP4
Pergunta aberta opcional				
ABR	O que mais dificulta, ou o que mais ajudou, o seu aprendizado de programação?	Texto → nominal	M8	QP1

4 Pré-teste

O pré-teste será aplicado em 13/11/2026 a [4] profissionais de TI que já atuam no mercado. Eles *não* fazem parte da amostra, porque não são estudantes dos períodos iniciais nem estagiários, mas já passaram pelo aprendizado de programação e conseguem julgar se os itens fazem sentido. Como a pergunta 2 encerraria o formulário para quem está fora da população, os participantes são orientados a responder pensando no início da graduação e a marcar "1º ao 4º período", para percorrer todas as perguntas. Cada participante responderá ao formulário final pensando em voz alta (entrevista cognitiva), presencialmente ou por chamada de vídeo. O grupo cronometrará a duração e fará uma conversa de encerramento com quatro perguntas: clareza dos itens, ambiguidade, duração percebida e itens sensíveis ou faltantes. Um item é reformulado quando ao menos dois participantes apontam o mesmo problema. As respostas do pré-teste são apagadas do formulário antes da abertura da coleta e não entram no conjunto de dados. O roteiro e o registro detalhado estão em `pre-teste/roteiro-pre-teste.md`.

Tabela 6: Resultado do pré-teste e mudanças feitas no instrumento.

Item	Problema observado (quem)	Mudança realizada	Duração
[ID]	[descrição; P1, P3]	[nova redação ou remoção]	[min]
[ID]	[descrição; P2, P4]	[nova redação ou remoção]	[min]
[ID]	[descrição]	[nova redação ou remoção]	[min]

A duração mediana observada no pré-teste foi de [X] min. O valor de referência usado na regra E5 (Seção 5) é a mediana da amostra real.

5 Plano de análise

5.1 Limpeza. As regras da Tabela 7 são aplicadas nesta ordem, e cada descarte é registrado com o seu motivo para alimentar o perfil da amostra no dashboard. Os registros descartados permanecem no arquivo bruto, para auditoria. Como o link é aberto, a taxa de resposta não pode ser calculada, o que os Empirical Standards aceitam para surveys abertos; em seu lugar, relata-se o número de respostas recebidas por dia de coleta.

Tabela 7: Regras de exclusão de respostas, na ordem de aplicação.

Regra	Motivo do descarte	Critério operacional	Itens
E1	Sem aceite ou menor de 18	Não concordou com o termo	ACE
E2	Fora da população	Curso *outro*, ou 5º período ou posterior sem estágio	CUR, ETA
E3	Falha na atenção	Qualquer resposta diferente de *Discordo totalmente*	ATN1
E4	Resposta retilínea incoerente	DIF1–DIF4 todos em 1 ou todos em 5, o que contradiz o item invertido DIF4	DIF
E5	Resposta rápida demais	Duração menor que 1/3 da mediana das durações	Início/fim
E6	Duplicata técnica	Respostas idênticas enviadas com menos de 5 min de diferença (mantém-se a primeira)	Todos

5.2 Codificação e dados ausentes. Os itens Likert são codificados de 1 a 5, e DIF4 é invertido ($6 - x$). O escore M1 é a média dos 4 itens DIF. Como todas as perguntas fechadas são obrigatórias, só há ausência na pergunta aberta (ABR), que é opcional; nenhuma imputação é feita. Para H3b, ETA é recodificada em dois grupos: períodos iniciais e estagiários.

5.3 Confiabilidade. Calcula-se o α de Cronbach dos 4 itens DIF, com a correlação item-total. Os critérios são: $\alpha \geq 0{,}70$ adequado; de 0,60 a 0,70 aceitável com ressalva; abaixo de 0,60, os itens passam a ser analisados separadamente, o que é declarado como desvio.

5.4 Estatística descritiva e testes. O relatório inclui frequências, mediana e intervalo interquartil, gráfico de barras divergentes para os itens Likert e proporções com IC de 95% (Wilson) acompanhadas da margem de erro. Nenhum teste supõe normalidade. Os testes e os tamanhos de efeito estão na Tabela 8.

Tabela 8: Testes coerentes com as escalas e tamanhos de efeito por hipótese.

Hipótese	Variáveis (escalas)	Teste	Tamanho de efeito (pequeno/médio/grande)
QP1	M1, M2 (ordinal; proporção)	Descritiva; IC de 95% de Wilson	Proporção ± margem de erro
H2	M1 × M3 (ordinal × nominal, 2 grupos)	Mann-Whitney U	δ de Cliff: 0,147/0,33/0,474 (ROMANO et al., 2006)
H3a	M1 × M4 (ordinal × 4 grupos)	Kruskal-Wallis; post hoc de Dunn	ε^2: 0,01/0,08/0,26 (TOMCZAK; TOMCZAK, 2014)
H3b	M1 × M5 (ordinal × nominal, 2 grupos)	Mann-Whitney U	δ de Cliff: 0,147/0,33/0,474
H3c	M3 × M4 (nominal × nominal)	χ^2 de independência[d]	V de Cramér: 0,1/0,3/0,5 (COHEN, 1988)
H4	M1 × M6 (ordinal × ordinal)	Correlação de Spearman	ρ com IC bootstrap (2.000 reamostras): 0,1/0,3/0,5

[d]Teste exato de Fisher quando alguma frequência esperada for menor que 5.

5.5 Decisão e múltiplas comparações. O nível de significância é $\alpha = 0{,}05$, com testes bilaterais. A **correção de Holm** (HOLM, 1979) é aplicada à família das cinco hipóteses confirmatórias (H2, H3a, H3b, H3c e H4), e também, separadamente, às comparações post hoc de Dunn. Para cada hipótese são relatados a estatística, o p ajustado, o tamanho de efeito com IC e a margem de erro. **Análise condicional (definida antes da coleta):** (i) se algum grupo de H2 ou H3b tiver $n < 10$, a hipótese é relatada apenas de forma descritiva; (ii) se algum curso tiver $n < 5$, os cursos são agrupados em bacharelados (CC, ES, SI) e tecnólogo (ADS), e H3a passa a usar Mann-Whitney; (iii) se o α de DIF for menor que 0,60, aplica-se a regra da Seção 5.3. **Análises exploratórias (rotuladas como tal):** uso de IA por curso e por etapa; H3b repetida apenas com quem não tinha experiência prévia, para separar o efeito do estágio do efeito da experiência.

5.6 Respostas abertas. ABR é analisada por codificação aberta indutiva (análise temática (BRAUN; CLARKE, 2006)). Dois integrantes codificam de forma independente 20% das respostas, calcula-se o κ de Cohen (com meta $\geq 0{,}60$), as divergências são resolvidas por consenso e o livro de códigos é consolidado. Em seguida, o restante é codificado e relata-se a frequência de cada tema (M8). Trechos que possam identificar alguém são removidos.

5.7 Ferramentas. A análise usa Python 3 (pandas, SciPy, pingouin), com scripts versionados no repositório. O dashboard da Parte 2 lê diretamente o arquivo bruto exportado do formulário.

6 Ética e LGPD

- **Enquadramento.** Trata-se de pesquisa de opinião com participantes não identificados, que a Resolução CNS nº 510/2016 (art. 1º, parágrafo único, I) dispensa de registro no sistema CEP/CONEP (BRASIL, 2016). Mesmo assim, o estudo segue as orientações da PUC Minas sobre pesquisas com pessoas e os princípios da resolução. Nenhuma lista de contatos de outras instituições é obtida: o convite circula apenas por intermediários e canais abertos.
- **Consentimento.** A abertura do formulário apresenta o TCLE (`instrumento/tcle.md`), que informa: objetivo, responsáveis, duração (cerca de 2 min), caráter voluntário, ausência de vínculo com notas, direito de desistir antes do envio (após o envio, a resposta anônima não pode ser localizada), riscos mínimos e contatos do grupo e do professor orientador. O aceite (ACE), que também confirma a idade mínima de 18 anos, é obrigatório para prosseguir.
- **Anonimização na origem.** O formulário é configurado como resposta anônima e não coleta nome, e-mail, matrícula, IP nem o nome da instituição. A pergunta aberta pede que não sejam citados nomes, e as respostas são revisadas para

remover qualquer dado identificador. O dashboard *não exibe segmentos com menos de 5 respondentes.*

- **LGPD.** Dados anonimizados não são dados pessoais (Lei nº 13.709/2018, art. 12) (BRASIL, 2018). Ainda assim, adotam-se o consentimento (art. 7º, I) e os princípios de finalidade, necessidade e segurança (art. 6º). O uso é exclusivamente acadêmico.
- **Armazenamento.** A exportação bruta fica na conta institucional do Microsoft 365, com acesso restrito ao grupo e ao professor, e será excluída logo após a defesa da Parte 2. O repositório público recebe apenas o conjunto anonimizado, sem textos livres não revisados.

7 Ameaças à validade

Tabela 9: Ameaças típicas de survey e mitigação, na classificação de validade de Wohlin et al. (2012).

Ameaça	Tipo	Mitigação
Autosseleção e rede dos autores	Externa	Convite neutro ("sua experiência com programação"), sem a palavra "dificuldade"; docentes e centros acadêmicos de outras instituições; metas por curso e etapa.
Não resposta e cobertura	Externa	Formulário de 2 minutos para elevar a adesão; dois lembretes; comparação entre quem respondeu cedo e tarde (ARMSTRONG; OVERTON, 1977); distribuição por curso comparada ao Censo da Educação Superior (INEP).
Desejabilidade social	Construto	Anonimato; nenhum vínculo com notas; redação neutra; integrantes não avaliam os respondentes.
Aquiescência e descuido	Construto	Item invertido (DIF4); pergunta de atenção (ATN1); regras E3–E5.
Construto com poucos itens	Construto	DIF tem 4 itens, o mínimo para estimar o α com estabilidade razoável; clareza e validade de conteúdo avaliadas no pré-teste. A dificuldade *percebida* não equivale a desempenho (limitação declarada).
Fatores não medidos	Interna	O instrumento curto não mede autoeficácia, ansiedade nem horas de estudo, que também afetam a dificuldade; os resultados são associações parciais, em linguagem não causal.
Confusão entre fatores	Interna	Etapa e experiência prévia tendem a andar juntas; análise exploratória estratificada (Seção 5.5).
Respostas automatizadas ou duplicadas	Construto	Sem incentivos; tempo mínimo (E5); atenção (ATN1); duplicatas (E6); opção do Forms que oculta "enviar outra resposta".
Generalização	Externa	Amostra não probabilística: conclusões restritas à amostra, margem nominal e composição descrita (cursos e etapas).
Múltiplos testes, poder e p-hacking	Conclusão	Correção de Holm; poder declarado e limitado a efeitos grandes ($\lvert\rho\rvert \geq 0{,}39$); hipóteses, testes e regras registrados antes da coleta.
Viés na codificação aberta	Conclusão	Dois codificadores; κ de Cohen $\geq 0{,}60$; livro de códigos publicado.

8 Plano de divulgação

Canais. (C1) Docentes de programação de outras instituições, que recebem uma mensagem pronta para repassar às turmas e, quando autorizado, abrem alguns minutos da aula para a resposta, com QR code. (C2) Centros e diretórios acadêmicos e grupos de estudantes de tecnologia (WhatsApp, Discord, Telegram), com permissão dos administradores. (C3) Perfis dos integrantes no LinkedIn e no Instagram, com pedido de compartilhamento (bola de neve). (C4) Dois lembretes nos mesmos canais. Cada postagem é registrada com captura de tela datada, como evidência para a Parte 2. **Monitoramento e contingência.** Em 25/11, a composição parcial é comparada às metas (8 respostas por curso e 10 estagiários), e a segunda onda é direcionada aos segmentos abaixo da meta. Se houver menos de 50 respostas válidas em 04/12, a coleta será estendida até 11/12, com novos canais, e a mudança será registrada como desvio.

Tabela 10: Cronograma da coleta (2026).

Data	Atividade
13/11 (sex)	Pré-teste, ajustes e registro do protocolo (commit e tag datados e envio na plataforma até 23:59)
16/11 e 17/11	Contato com docentes e centros acadêmicos de outras instituições; preparação das peças de divulgação
18/11 (qua)	Abertura do formulário e primeira onda de divulgação (C1–C3)
25/11 (qua)	Verificação das metas por segmento; segunda onda direcionada e lembrete 1 (C4)
02/12 (qua)	Lembrete 2 (C4)
04/12 (sex)	Encerramento da coleta às 23:59; exportação bruta datada
a partir de 07/12	Limpeza, análise, dashboard e registro de desvios (Parte 2)

Referências

ARMSTRONG, J. S.; OVERTON, T. S. Estimating nonresponse bias in mail surveys. *Journal of Marketing Research*, v. 14, n. 3, p. 396–402, 1977.

BALTES, S.; RALPH, P. Sampling in software engineering research: a critical review and guidelines. *Empirical Software Engineering*, v. 27, 2022. DOI: 10.1007/s10664-021-10072-8.

BASILI, V. R.; CALDIERA, G.; ROMBACH, H. D. The goal question metric approach. In: *Encyclopedia of Software Engineering*. New York: Wiley, 1994.

BECKER, B. A. et al. Programming is hard – or at least it used to be. In: *Proc. 54th ACM Technical Symposium on Computer Science Education (SIGCSE)*. ACM, 2023. DOI: 10.1145/3545945.3569759.

BRAUN, V.; CLARKE, V. Using thematic analysis in psychology. *Qualitative Research in Psychology*, v. 3, n. 2, p. 77–101, 2006.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, 2018.

BRASIL. Conselho Nacional de Saúde. Resolução nº 510, de 7 de abril de 2016. Brasília, 2016.

COHEN, J. *Statistical power analysis for the behavioral sciences*. 2. ed. Hillsdale: Lawrence Erlbaum, 1988.

CONNOLLY, C.; MURPHY, E.; MOORE, S. Programming anxiety amongst computing students – a key in the retention debate? *IEEE Transactions on Education*, v. 52, n. 1, 2009. DOI: 10.1109/TE.2008.917193.

HOLM, S. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, v. 6, n. 2, p. 65–70, 1979.

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA (INEP). *Censo da Educação Superior 2024*: resultados. Brasília: Inep, 2025. Disponível em: https://download.inep.gov.br.

KITCHENHAM, B. A.; PFLEEGER, S. L. Personal opinion surveys. In: SHULL, F.; SINGER, J.; SJØBERG, D. (ed.). *Guide to Advanced Empirical Software Engineering*. London: Springer, 2008. DOI: 10.1007/978-1-84800-044-5_3.

LAHTINEN, E.; ALA-MUTKA, K.; JÄRVINEN, H.-M. A study of the difficulties of novice programmers. In: *Proc. 10th ITiCSE*. ACM, 2005. DOI: 10.1145/1067445.1067453.

RALPH, P. et al. *ACM SIGSOFT Empirical Standards*: Questionnaire Surveys; Registered Reports. 2021. Disponível em: https://github.com/acmsigsoft/EmpiricalStandards.

RAMALINGAM, V.; WIEDENBECK, S. Development and validation of scores on a computer programming self-efficacy scale and group analyses of novice programmer self-efficacy. *Journal of Educational Computing Research*, v. 19, n. 4, 1998. DOI: 10.2190/C670-Y3C8-LTJ1-CT3P.

ROBINS, A.; ROUNTREE, J.; ROUNTREE, N. Learning and teaching programming: a review and discussion. *Computer Science Education*, v. 13, n. 2, p. 137–172, 2003.

ROMANO, J. et al. Appropriate statistics for ordinal level data. In: *Annual Meeting of the Florida Association of Institutional Research*, 2006.

TOMCZAK, M.; TOMCZAK, E. The need to report effect size estimates revisited. *Trends in Sport Sciences*, v. 1, n. 21, p. 19–25, 2014.

WATSON, C.; LI, F. W. B. Failure rates in introductory programming revisited. In: *Proc. ITiCSE '14*. ACM, 2014. DOI: 10.1145/2591708.2591749.

WOHLIN, C. et al. *Experimentation in Software Engineering*. Berlin: Springer, 2012.